Tecnológico de Monterrey

Clasificación morfológica de galaxias mediante fusión multimodal de imágenes DESI Legacy y espectros integrados MaNGA

Alexander Carreño María Rabelero
Julio Ricardo Velázquez

Proyecto Integrador · Maestría en Inteligencia Artificial Aplicada

Asesores: Dr. José Antonio Vázquez Mata y Dr. Hector Manuel Hernandez Toledo · 9 de Noviembre 2026

Resumen

La clasificación morfológica de galaxias es fundamental para estudiar su formación y evolución, pero la clasificación visual experta limita la escalabilidad frente al creciente volumen de observaciones astronómicas. Este proyecto evaluó modelos de aprendizaje profundo para distinguir galaxias tempranas y tardías utilizando imágenes ópticas de Legacy Survey, espectros integrados MaNGA y propiedades de poblaciones estelares derivadas mediante STARLIGHT. Se construyó una cohorte alineada de 9,351 galaxias, dividida mediante un protocolo estratificado persistente en 6,545 objetos de entrenamiento, 1,403 de validación y 1,403 de prueba.

Los resultados muestran que la información visual constituye la referencia predictiva más fuerte. El clasificador visual seleccionado alcanzó ROC-AUC de 0.9667, exactitud de 0.8952 y exactitud balanceada de 0.8980. Frente al umbral de aceptación heredado, definido en términos de exactitud de 0.829, el resultado representa una mejora absoluta de 0.0662, equivalente a 6.62 puntos porcentuales. En contraste, el baseline ResNet-18 obtuvo ROC-AUC de 0.9633 y exactitud de 0.8881.

El mejor modelo espectral, patch-BiGRU sobre FLUX_FoV, mejoró el ROC-AUC de 0.8572 de la CNN1D de referencia hasta 0.9170. Las fusiones por concatenación no demostraron una mejora frente a la imagen sola. No obstante, las poblaciones estelares corrigieron el 51.6 % de los errores de ResNet-18. Los errores se concentran en la frontera morfológica T-Type 0–1. Los resultados respaldan desplegar el clasificador visual como referencia y evaluar posteriormente una fusión adaptativa y calibrada que aprenda cuándo utilizar evidencia complementaria.

Palabras clave. morfología galáctica, aprendizaje profundo, fusión multimodal, MaNGA, DESI Legacy Surveys, CRISP-ML(Q).

1. Contexto de negocio y problema

1.1. Contexto institucional

El beneficiario es el grupo de Galaxias y Cosmología del Instituto de Astronomía de la UNAM (IA-UNAM). Este grupo es responsable del MaNGA Visual Morphology Value Added Catalogue,

que contiene la clasificación visual de 10,059 galaxias del sondeo MaNGA (SDSS-IV) (Vázquez-Mata et al., 2025). El proceso impactado es la producción de catálogos morfológicos: un experto inspecciona cada imagen y asigna un tipo en la secuencia de Hubble, resumido por el índice numérico T-Type (Figura 1 y Figura 2).

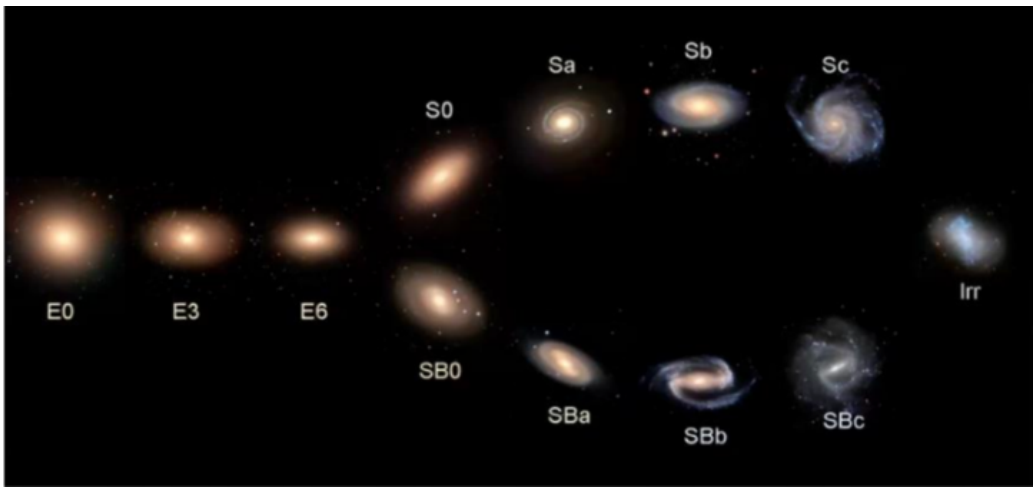


Figura 1: Secuencia de Hubble y esquema del índice T-Type.

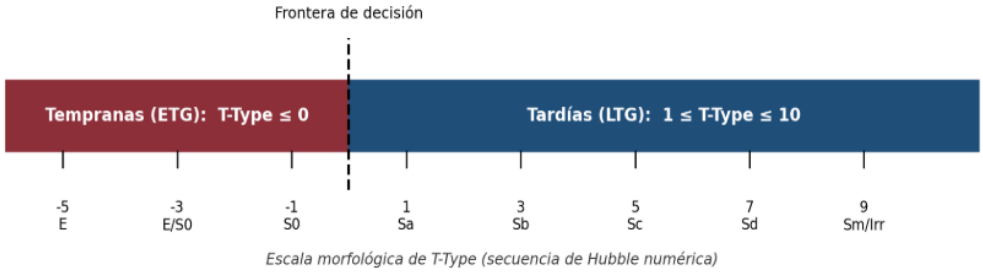


Figura 2: Las galaxias con T-Type ≤ 0 (elípticas y lenticulares) se etiquetan como tempranas (0), y aquellas que cumplen $1 \leq$ T-Type ≤ 10 (espirales e irregulares) como tardías (1).

El proyecto formula el problema como aprendizaje supervisado. Para una galaxia el sistema debe estimar una probabilidad de pertenencia a una de dos clases:

- temprana: $Ttype \leq 0$;
- tardía: $1 \leq Ttype \leq 10$.

La formulación binaria reduce el problema de escasez que aparece al utilizar directamente las numerosas subclases morfológicas presentes en el catálogo.

1.2. Objetivo analítico

El objetivo consiste en determinar hasta qué punto la información contenida en imágenes, espectros y propiedades derivadas de poblaciones estelares permite reproducir el criterio morfológico

experto sobre galaxias no vistas.

Además de maximizar el desempeño predictivo, el proyecto busca determinar si diferentes modalidades aportan información complementaria. Por ello se compararon modelos unimodales con diversas configuraciones multimodales utilizando una cohorte común.

También planteó reducir el esfuerzo de clasificación y revisión sin incurrir en costos computacionales desproporcionados (Carreño Correa et al., 2026)

1.3. Evolución del enfoque

La hipótesis inicial proponía que combinar imágenes ópticas con información espectroscópica produciría un clasificador superior a una modalidad aislada. Las imágenes contienen estructura directamente relacionada con brazos, bulbo, disco e inclinación, mientras los espectros contienen señales asociadas con poblaciones estelares, metalicidad y formación estelar. Los experimentos modificaron esta hipótesis. La evolución del proyecto puede sintetizarse como:

Datos → Baseline visual → Ablación multimodal → Mejora espectral → Complementariedad → Fusión adaptativa

La imagen resultó ser una referencia difícil de superar. Los modelos multimodales basados en concatenación no produjeron una mejora estadísticamente defendible. Al mismo tiempo, el análisis por galaxia mostró que las modalidades no cometen siempre los mismos errores.

La decisión principal del proyecto cambió entonces de construir un modelo con más modalidades a investigar un mecanismo capaz de aprender cuándo confiar en cada experto.

2. Datos y preparación

2.1. Fuentes de información

El proyecto utiliza tres representaciones relacionadas de las mismas galaxias:

1. Imágenes RGB de Legacy Survey
2. Espectros integrados MaNGA
3. Propiedades de poblaciones estelares derivadas con STARLIGHT

El manifest maestro contiene 10,014 objetos. Después de alinear disponibilidad e identidad entre modalidades se obtuvo una cohorte experimental de 9,351 galaxias.

Para las imágenes se dispuso de 10,006 objetos por factor de campo de visión. Los recortes tienen una resolución de 256×256 píxeles y combinan las bandas g, r y z.

Para espectros MaNGA se encontraron 10,013 archivos FITS correspondientes a los 10,014 objetos del catálogo. Los archivos contienen WAVE, FLUX_1RE, FLUX_FoV, ERROR_1RE y ERROR_FoV.

STARLIGHT proporciona una representación derivada del espectro mediante 45 plantillas y 90 características relacionadas con fracciones de luz y masa de poblaciones estelares. Estos productos no deben interpretarse como una observación independiente, pues proceden del mismo espectro FLUX_FoV.

2.2. Control de calidad de imágenes

El análisis exploratorio detectó diferencias de orientación entre los productos FITS y JPEG. Corregir la orientación vertical incrementó la correlación media píxel a píxel de aproximadamente 0.731 a 0.980 en la muestra de control.

También se identificaron diferencias fotométricas entre observaciones del norte y del sur. Parte de dichas diferencias se relaciona con los sistemas de observación y con la construcción de los productos RGB. Esto representa un riesgo de contaminación: un clasificador podría aprender características asociadas al origen instrumental antes que a la morfología.

El análisis fotométrico encontró además que el color $g - r$ y la concentración presentan señal morfológica útil. En la muestra exploratoria, $g - r$ alcanzó AUC de aproximadamente 0.95 y la concentración un AUC de 0.89, resultados utilizados como controles de sanidad y no como sustitutos del modelo visual.

2.3. Preparación de espectros

Los espectros fueron inspeccionados para comprobar integridad, cobertura y valores no finitos. La preparación posterior generó representaciones de 4,096 puntos junto con una máscara que permite identificar posiciones válidas.

El procedimiento contempla transformación al marco de reposo, normalización e interpolación en una malla común. Durante el análisis exploratorio se identificó como restricción verificar previamente que la variable de longitud de onda y el redshift utilizado correspondan al marco esperado antes de aplicar transformaciones físicas.

2.4. Cohorte y separación experimental

Se utilizó una partición estratificada persistente con semilla 42. La Tabla 1 resume la cohorte.

Tabla 1: Distribución de la cohorte experimental empleada en las ramas comparables del proyecto.

Partición	Total	Tardías	Tempranas
Entrenamiento	6,545	4,078	2,467
Validación	1,403	874	529
Prueba	1,403	875	528

Mantener los mismos identificadores entre modalidades permitió comparar modelos evitando cambios silenciosos de población. El conjunto de prueba permaneció reservado para evaluación y las variables Ttype, Type y label no se utilizaron como predictores.

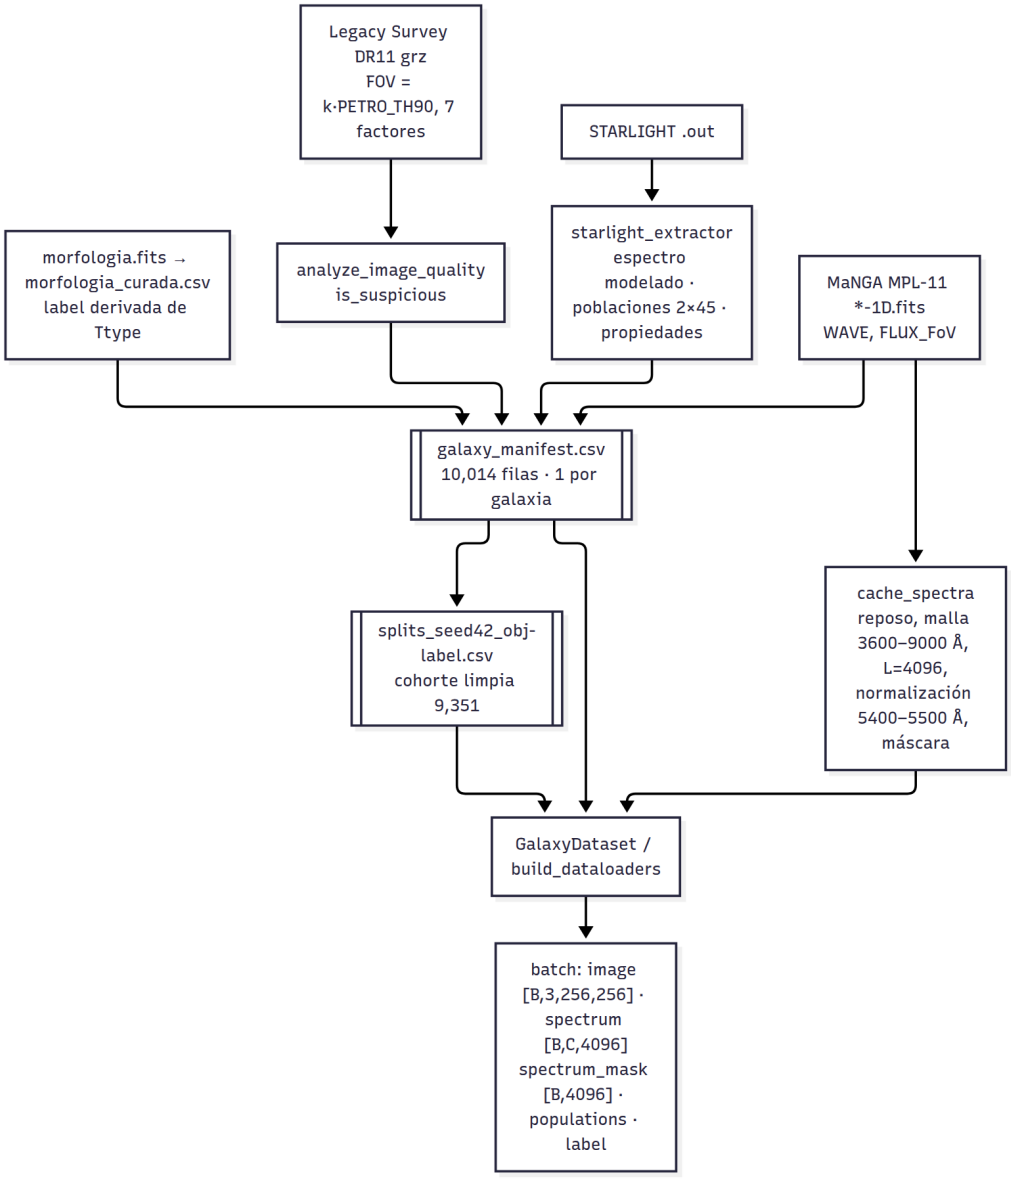


Figura 3: Flujo de datos: catálogo → *manifest* → descarga y control de calidad de imágenes / caché espectral / poblaciones → partición persistente → `GalaxyDataset`.

3. Metodología y modelos

3.1. Baseline visual

El baseline reproducible se construyó utilizando un ResNet-18 inicializado aleatoriamente (He et al., 2016) sobre imágenes RGB. El modelo utilizó imágenes de 256×256 píxeles, batch de 32, BCEWithLogitsLoss y AdamW.

La configuración inicial empleó learning rate de 10^{-4} y weight decay de 10^{-4}. La selección del checkpoint se realizó utilizando ROC-AUC de validación y early stopping.

El máximo ROC-AUC de validación fue 0.9644 en la época 24. En el conjunto de prueba el

modelo obtuvo:

- ROC-AUC: 0.9633
- accuracy: 0.8881
- balanced accuracy: 0.8825
- macro F1: 0.8812

Este resultado estableció una referencia visual fuerte frente a la cual se compararon los modelos posteriores.

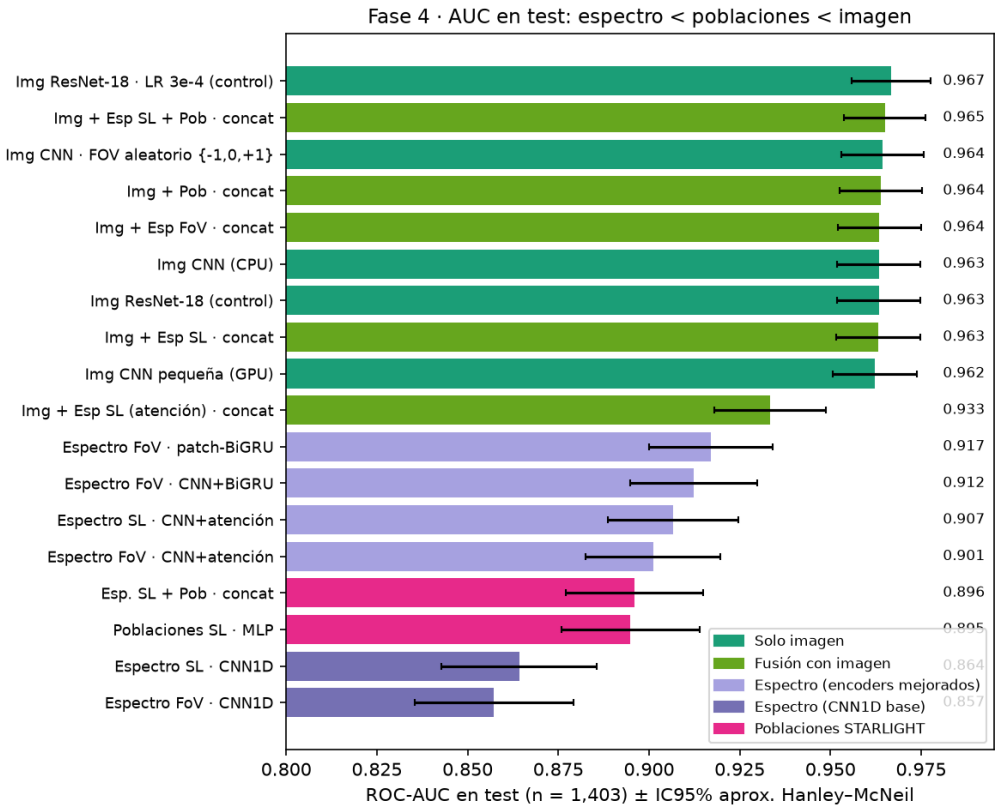


Figura 4: ROC-AUC en prueba de todos los experimentos, agrupados por modalidad.

3.2. Modelos candidatos

La fase de ablación incluyó:

- CNN visual compacta;
- ResNet-18;
- CNN1D sobre FLUX_FoV;
- CNN1D sobre espectro STARLIGHT;

- MLP sobre poblaciones STARLIGHT;
- combinaciones RGB + espectro;
- RGB + poblaciones;
- configuración trimodal.

Las ramas comparables utilizaron BCEWithLogitsLoss, AdamW y selección del checkpoint mediante ROC-AUC de validación.

3.3. Resultados de la ablación

La Tabla 2 resume los experimentos principales.

Tabla 2: Comparación de modelos principales sobre el conjunto de prueba.

Modelo	ROC-AUC	Accuracy
Imagen CNN	0.9623	0.901
Imagen ResNet-18	0.9633	0.888
RGB + espectro + poblaciones	0.9650	0.890
Poblaciones STARLIGHT	0.8949	0.838
Espectro STARLIGHT CNN1D	0.8642	0.789
Espectro FoV CNN1D	0.8572	0.795

La combinación trimodal alcanzó ROC-AUC de 0.9650 frente a 0.9633 para ResNet-18. La diferencia, aproximadamente 0.0017, es menor que la incertidumbre de AUC estimada alrededor de 0.005. Por ello la mejora no se consideró demostrada.

3.4. Replanteamiento del experto espectral

El resultado de CNN1D motivó evaluar si la limitación provenía de la modalidad o de la representación aprendida. Se compararon CNN1D, attention pooling, CNN+BiGRU y patch-BiGRU. Los resultados se presentan en la Tabla 3.

Tabla 3: Evolución de modelos sobre el espectro FoV observado.

Modelo	ROC-AUC	Accuracy
CNN1D	0.8572	0.795
Atención	0.9011	0.842
CNN + BiGRU	0.9122	0.847
Patch + BiGRU	0.9170	0.852

Patch-BiGRU incrementó el ROC-AUC en 0.0598 frente a CNN1D. Esta comparación debe interpretarse con cautela porque la arquitectura y varios parámetros de optimización cambiaron conjuntamente.

3.5. Selección del modelo final

La mejor referencia visual observada corresponde a una CNN compacta de aproximadamente 1.2 millones de parámetros, con ROC-AUC de 0.9667, accuracy de 0.8952 y balanced accuracy de 0.8980.

El resultado es particularmente relevante porque la red compacta iguala o supera a configuraciones visuales mucho mayores, reduciendo el costo potencial de inferencia.

Un experimento de fusión que combinó la rama de imagen con un encoder espectral STARLIGHT más fuerte obtuvo ROC-AUC de 0.9334 y accuracy de 0.862. El control visual correspondiente alcanzó ROC-AUC de 0.9667 y accuracy de 0.895.

La diferencia pareada de AUC entre fusión y control fue de aproximadamente $-0{,}0333$, con un intervalo de confianza que excluyó cero. Bajo este experimento, incorporar una rama espectral no mejora al clasificador visual.

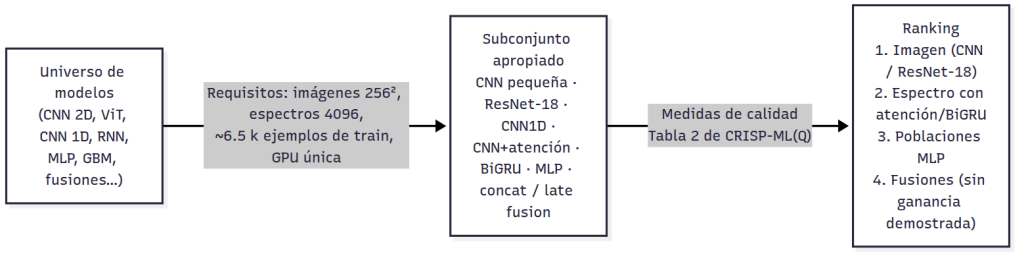


Figura 5: Seleccion del modelo: entrada RGB de 256×256 píxeles $\rightarrow$ 4 bloques de doble `Conv2d-BN-ReLU` ($32 \rightarrow 256$ canales) $\rightarrow$ `AdaptiveAvgPool2d` $\rightarrow$ proyección a 128 dimensiones $\rightarrow$ MLP $\rightarrow$ logit.

4. Resultados y validación

4.1. Modelo final frente al baseline

La Tabla 4 resume las cifras decisivas.

Tabla 4: Comparación de la referencia inicial, modelo seleccionado y umbral heredado de aceptación.

Referencia	ROC-AUC	Accuracy	Balanced accuracy
Umbral heredado	–	0.8290	–
ResNet-18 baseline	0.9633	0.8881	0.8825
CNN visual seleccionada	0.9667	0.8952	0.8980

La métrica primaria para selección durante los experimentos fue ROC-AUC. Para contrastar el requisito de aceptación heredado se utiliza accuracy. La brecha del modelo seleccionado respecto al umbral de 0.829 es:

$$0{,}8952 - 0{,}8290 = 0{,}0662$$

lo que corresponde a una mejora absoluta de 6.62 puntos porcentuales. Frente al baseline ResNet-

18, el aumento de ROC-AUC es:

$$0{,}9667 - 0{,}9633 = 0{,}0034.$$

La magnitud es pequeña y debe evaluarse bajo la limitación de haber utilizado una sola semilla en varios experimentos. La conclusión principal no es que una variante visual sea universalmente superior, sino que la familia de modelos visuales alcanza de forma estable el orden de ROC-AUC 0.96 dentro del protocolo observado.

4.2. Complementariedad de los errores

La comparación por galaxia mostró que ResNet-18 cometió 157 errores sobre las 1,403 observaciones de prueba. El modelo de poblaciones clasificó adecuadamente el 51.6 % de esos casos.

Un oráculo que pudiera seleccionar retrospectivamente entre RGB y poblaciones aumentaría accuracy de 0.888 a 0.946.

Este resultado no representa un clasificador desplegable porque utiliza la etiqueta verdadera para decidir qué experto elegir. Su relevancia es diagnóstica: demuestra que existe información complementaria que las fusiones evaluadas no consiguieron aprovechar.

La fusión tardía con peso global produjo solamente una variación de AUC de +0.0005, con IC95 % de $[-0{,}0012, +0{,}0022]$. Por tanto, la complementariedad de errores no implica automáticamente una mejora del ensamble.

4.3. Errores en la frontera morfológica

El error se concentra alrededor de T-Type 0–1:

- 16.1 % de las galaxias se encuentran en esta región;
- 47.8 % de los errores RGB ocurren allí;
- la tasa de error RGB en la frontera alcanza 33.2 %;
- fuera de la frontera el error desciende a 7.0 %.

Esto modifica la interpretación del error desde la perspectiva del dominio. Parte de las predicciones incorrectas corresponde a una zona en la que las clases presentan características físicas y visuales continuas, especialmente alrededor de la separación S0/Sa.

Ninguna propiedad individual de STARLIGHT separó significativamente los errores después de aplicar corrección de Bonferroni. Una regla manual basada en una propiedad física aislada no queda respaldada por la evidencia experimental.

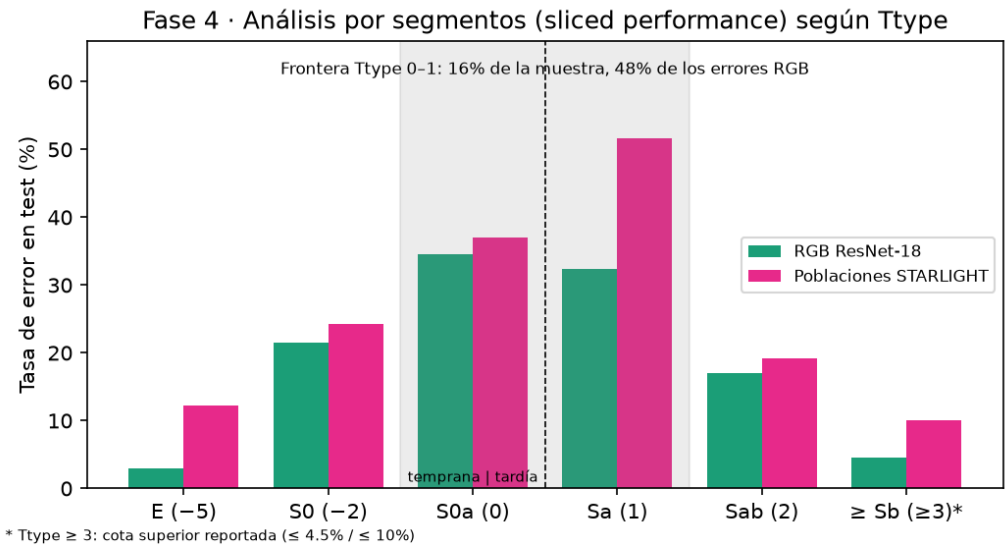


Figura 6: Tasa de error según T-Type.

4.4. Limitaciones

Las conclusiones deben interpretarse considerando varias limitaciones.

Primero, los experimentos visuales principales utilizaron una sola semilla y no todos fueron repetidos. Diferencias pequeñas entre modelos no permiten construir un ranking robusto.

Segundo, existen riesgos instrumentales identificados durante el EDA, incluyendo diferencias regionales norte-sur y transformaciones de imagen.

Tercero, STARLIGHT deriva sus productos del mismo espectro FoV, por lo que espectro y poblaciones no constituyen observaciones independientes.

Cuarto, varios experimentos espectrales modificaron simultáneamente arquitectura y optimización. El incremento observado no puede atribuirse exclusivamente a BiGRU.

5. Implementación y operación

5.1. Arquitectura propuesta

El repositorio experimental ya separa manifest, dataset, encoders, clasificación, entrenamiento y evaluación. Para una operación futura se propone conservar dichos límites funcionales. La Figura **??** presenta la arquitectura lógica de despliegue.

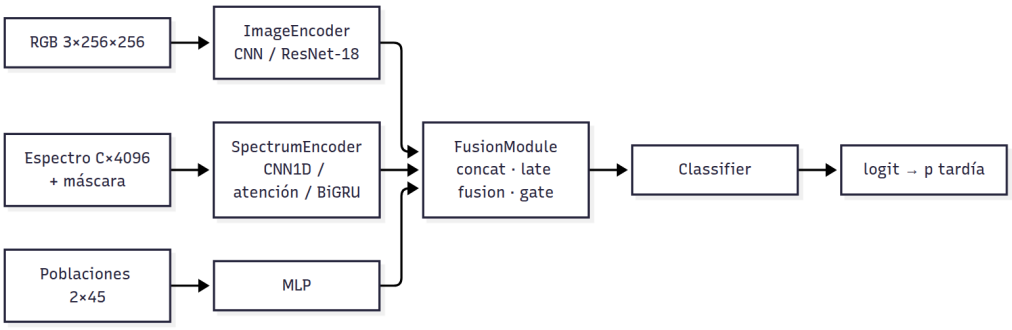


Figura 7: Arquitectura del modelo final: entrada RGB de 256×256 píxeles $\rightarrow$ 4 bloques de doble `Conv2d-BN-ReLU` ($32 \rightarrow 256$ canales) $\rightarrow$ `AdaptiveAvgPool2d` $\rightarrow$ proyección a 128 dimensiones $\rightarrow$ MLP $\rightarrow$ logit.

La recomendación es desplegar inicialmente la CNN visual seleccionada, evitando introducir la complejidad de las ramas adicionales hasta demostrar una ganancia reproducible.

5.2. Responsabilidades

La Tabla 5 propone responsabilidades operativas.

Tabla 5: Responsabilidades propuestas para operación de la solución.

Componente	Responsable sugerido
Etiquetas y criterios científicos	Especialista de dominio IA-UNAM
Ingesta Legacy/MaNGA	Data Engineer
Manifest y preprocesamiento	Data Engineer / ML Engineer
Entrenamiento y evaluación	Data Scientist
Serving de inferencia	ML Engineer
Infraestructura y automatización	MLOps / Cloud Engineer
Validación científica	Sponsors e investigadores IA-UNAM
Monitoreo del modelo	ML Engineer + especialista de dominio

5.3. Monitoreo

La operación debería supervisar cuatro grupos de indicadores.

Datos. Disponibilidad de imágenes, integridad de entradas, resolución, identificadores, distribución por región y porcentaje de observaciones rechazadas.

Modelo. Distribución de probabilidades, accuracy, balanced accuracy, ROC-AUC, recall por clase y matriz de confusión cuando se disponga de nuevas etiquetas.

Calibración. Expected Calibration Error, Brier score y curvas de confiabilidad, especialmente si la probabilidad del modelo se utiliza para triaje o selección entre expertos.

Subgrupos. Desempeño por T-Type, masa y otras características físicamente relevantes. La región T-Type 0–1 requiere seguimiento diferenciado.

La promoción de un nuevo modelo debería requerir comparación contra la CNN RGB de referencia, ausencia de fuga de información, evaluación sobre varias semillas y una ganancia estadísticamente defendible frente al costo adicional de inferencia.

6. Conclusiones clave

El proyecto permite establecer cinco conclusiones principales.

Primero, la información visual es el predictor más fuerte de los evaluados. Los clasificadores RGB alcanzaron ROC-AUC cercano a 0.96 y accuracy alrededor de 89–90 %. La CNN visual seleccionada alcanzó ROC-AUC de 0.9667, accuracy de 0.8952 y balanced accuracy de 0.8980.

Segundo, el modelo seleccionado supera el umbral heredado de accuracy 0.829 por 6.62 puntos porcentuales.

Tercero, el desempeño inicial más bajo de los espectros no se explica únicamente por falta de información. Cambiar la representación de CNN1D hacia atención y BiGRU incrementó el ROC-AUC FoV desde 0.8572 hasta 0.9170.

Cuarto, complementariedad y fusión no son equivalentes. Las poblaciones estelares corrigieron 51.6 % de los errores de ResNet-18, pero las estrategias de combinación evaluadas no transformaron esa complementariedad en una mejora reproducible.

Quinto, la principal concentración de errores aparece alrededor de la frontera T-Type 0–1. Esta región representa 16.1 % de las galaxias, pero acumula 47.8 % de los errores RGB.

Por estas razones, la recomendación operativa es utilizar el modelo visual como referencia y reservar la multimodalidad para una siguiente etapa experimental.

El trabajo futuro debe evaluar entre tres y cinco semillas, utilizar intervalos pareados, estudiar calibración mediante ECE y Brier score y evaluar un decisor ligero mediante late fusion, stacking con predicciones out-of-fold o gating. La hipótesis futura puede expresarse como:

$$p_{\text{final}} = \alpha(x)p_{\text{RGB}} + [1 - \alpha(x)]p_{\text{experto}},$$

donde $\alpha(x)$ se aprende para cada galaxia utilizando únicamente datos de entrenamiento y validación. El conjunto de prueba debe permanecer bloqueado durante el ajuste del decisor.

Declaración de uso de inteligencia artificial

Se utilizó Microsoft Copilot como apoyo para integrar, estructurar y revisar la redacción del producto de difusión a partir de los documentos, resultados y cuadernos suministrados por los autores. Las conclusiones, métricas y decisiones técnicas fueron contrastadas contra los artefactos del proyecto.

Referencias

Carreño Correa, A., Rabelero, M., & Velázquez, J. R. (2026). *Clasificación morfológica de galaxias mediante fusión multimodal de imágenes DESI Legacy y espectros integrados MaNGA* (Proyecto Integrador). Instituto de Astronomía, Universidad Nacional Autónoma de México.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.

Vázquez-Mata, J. A., Hernández-Toledo, H. M., Avila-Reese, V., Rodríguez-Puebla, A., Martínez-Vázquez, L. A., Herrera-Endoqui, M., Lacerna, I., Mascherpa, L. C., & Morell, D. F. (2025). Visual morphological classification of the full MaNGA DR17 sample: a general characterization. *Monthly Notices of the Royal Astronomical Society*, *544*(1), 1056-1084. https://doi.org/10.1093/mnras/staf1784