Clasificación morfológica de galaxias usando espectros e imágenes: de la hipótesis multimodal a un clasificador visual verificable

[Nombre(s) del equipo]
Proyecto Integrador · Producto de difusión

Noviembre de 2026

Resumen

La clasificación morfológica de galaxias en tempranas (elípticas y lenticulares) y tardías (espirales e irregulares) sigue dependiendo de la inspección visual, un proceso lento y subjetivo que no escala a los catálogos del Observatorio Vera C. Rubin (LSST). Este trabajo evaluó si combinar imágenes ópticas del Legacy Survey con espectros integrados de MaNGA y productos de síntesis de poblaciones estelares de STARLIGHT mejora la clasificación binaria frente a una sola modalidad. Con una cohorte alineada de 9,351 galaxias y una partición estratificada única (6,545/1,403/1,403), se construyó una línea base visual (ResNet-18; ROC-AUC = 0.9633, exactitud = 88.8 %) y se compararon encoders espectrales, de poblaciones y fusiones por concatenación bajo el mismo protocolo. La imagen dominó: el mejor modelo, una CNN visual entrenada con tasa de aprendizaje 3×10^{-4}, alcanzó ROC-AUC = 0.9667 y exactitud = 89.5 %, superando el umbral de aceptación (AUC $\geq$ 0.95) por 0.0167, con un incremento de +0.0034 sobre la línea base, inferior a la incertidumbre estimada del AUC ($\approx$ 0.005). Ninguna fusión mejoró de forma estadísticamente demostrable (fusión tardía: ΔAUC = +0.0005, IC 95 % [−0.0012, +0.0022]). Sin embargo, los errores no son idénticos: el experto de poblaciones acierta 51.6 % de los errores visuales, y el 47.8 % de esos errores se concentra en la frontera Ttype 0–1, donde la etiqueta humana es más ambigua. Se recomienda operar el clasificador visual con calibración y revisión experta en la zona incierta, y se plantea como trabajo futuro un decisor adaptativo por galaxia.

Palabras clave: morfología galáctica, aprendizaje profundo, multimodalidad, MaNGA, Legacy Survey, CRISP-ML(Q).

Índice

1. Contexto de negocio y problema

1.1. El problema científico como problema de "negocio"

La división entre galaxias tempranas (ETG) y tardías (LTG) es la partición de primer orden de la secuencia de Hubble y el punto de partida de casi cualquier estudio estadístico de poblaciones galácticas (**??**). Históricamente se ha resuelto mediante inspección visual por especialistas: un proceso costoso, poco reproducible y con dispersión apreciable entre clasificadores independientes, sobre todo en los tipos intermedios. Los catálogos visuales que sustentan este proyecto (**??**) muestran a la vez el valor y el costo humano de este enfoque. La llegada de LSST (**?**), con miles de millones de galaxias, vuelve inviable la clasificación manual y convierte la automatización en una necesidad operativa.

En términos de CRISP-ML(Q) (**?**), el "cliente" es la comunidad astronómica que explota catálogos; el producto es una probabilidad $P(\text{tardía})$ por galaxia, fiable, reproducible y escalable; y el valor se mide en tres niveles: científico (clasificación confiable), de aprendizaje automático (métricas en prueba ciega) y económico (costo y cobertura frente a la revisión humana).

1.2. Planteamiento original (Avance 0)

El planteamiento inicial formuló una hipótesis de complementariedad: la imagen codifica la *forma* (concentración de luz, disco, brazos, barras) y el espectro la *física* (edad de las poblaciones estelares, quiebre de 4000 Å, líneas de emisión ligadas a formación estelar). Por ello se esperaba que un modelo que combinara imagen y espectro superara a cualquier modalidad aislada. La etiqueta binaria se definió a partir de Ttype: temprana si Ttype ≤ 0 y tardía si $1 \leq$ Ttype ≤ 10. El alcance comprendió las fases 1 a 4 de CRISP-ML(Q); el despliegue y el monitoreo quedaron fuera de alcance, aunque sus requisitos se anticipan en la Sección **??**.

1.3. Criterios de éxito acordados

La Tabla **??** resume los umbrales propuestos en la fase de entendimiento del negocio. Son el patrón contra el que se juzga el resultado en la Sección **??**.

Tabla 1: Criterios de éxito del proyecto (propuesta de la fase 1 de CRISP-ML(Q)).

Nivel	**Criterio**	**Cómo se mide**
Científico	Clasificación ETG/LTG fiable y reproducible; demostrar que imagen + espectro supera a la mejor modalidad individual	Informe revisado por experto de dominio
ML (mínimo aceptable)	ROC-AUC ≥ 0.95; exactitud balanceada ≥ 0.90; ECE ≤ 0.05; mejora multimodal con IC 95 % que excluya 0	Prueba ciega; bootstrap; McNemar
Económico	Costo por galaxia; galaxias por hora-GPU; cobertura con precisión $\geq 95\,\%$ (el resto a revisión humana)	Registro de tiempos; curva cobertura-precisión

1.4. Cambio de enfoque: el enfoque finalmente adoptado

El proyecto modificó su enfoque en tres puntos, todos documentados durante los avances:

1. **Espectro de referencia.** El Avance 0 proponía iniciar con el espectro a un radio efectivo (`Flux_1re`); el pipeline final usó el espectro integrado en todo el campo del instrumento (`FLUX_FoV`), registrado como decisión versionada.
2. **Del modelo de fusión como protagonista a la imagen como referencia.** La ablación mostró que la imagen concentra casi toda la señal predictiva y que concatenar ramas no la mejora de forma demostrable. El modelo recomendado para operación es, por tanto, un clasificador *visual*.
3. **Reformulación de la hipótesis multimodal.** La pregunta pasó de "¿la fusión supera a la imagen?" a "¿se puede aprender, *galaxia por galaxia*, cuándo confiar en la imagen y cuándo en el experto físico?". Esta hipótesis queda como trabajo futuro (Sección **??**).

Este cambio es coherente con el escenario de explotación: LSST proporcionará imágenes, pero no espectros, para la gran mayoría de galaxias; un clasificador que dependa del espectro tendría una cobertura operativa reducida.

2. Datos y preparación

2.1. Fuentes y unidad de análisis (Avance 1)

La unidad de análisis es la galaxia. Cuatro fuentes se unen por el nombre del objeto:

- **Catálogo morfológico** (`morfologia.fits`): nombre, Ttype (etiqueta) y `PETRO_TH90`, el radio que encierra el 90 % del flujo petrosiano, usado para normalizar el encuadre.
- **Imágenes RGB** del Legacy Survey (**?**), capas `ls-dr11`, bandas g, r, z, recortes de 256×256 píxeles con siete encuadres; se dispone de 10,006 imágenes por factor de encuadre.
- **Espectros integrados** de MaNGA (**?**), MPL-11, en FITS con `WAVE`, `FLUX_FoV`, `FLUX_1RE` y errores; 10,013 archivos presentes de 10,014 objetos.
- **Productos STARLIGHT** (**?**): espectro sintético del mejor ajuste y fracciones de luz y masa para 45 plantillas (90 atributos de población).

Advertencia de independencia. STARLIGHT no es una observación independiente: sus productos se derivan del mismo `FLUX_FoV`. Comparar o fusionar "espectro" y "poblaciones" no equivale a agregar una tercera fuente de información física; es una reparametrización del mismo dato.

2.2. Preparación y cohorte (Avance 2)

La preparación se diseñó para que todos los experimentos fueran comparables:

- **Encuadre adaptativo**: FOV $= k \times$ `PETRO_TH90`, de modo que galaxias grandes y pequeñas ocupen una fracción comparable del recorte y la red aprenda forma, no tamaño angular.
- **Espectros**: cachés de 4,096 puntos en marco de reposo, con máscaras de calidad.
- **Manifest maestro** de 10,014 filas con identidad, disponibilidad y calidad por modalidad; la intersección completa produjo una **cohorte alineada de 9,351 galaxias**.
- **Partición única y persistente** estratificada (semilla 42), compartida por todas las ramas; el conjunto de prueba se reserva. Ttype, `Type` y la etiqueta se excluyen explícitamente como atributos para impedir fuga de información.

Tabla 2: Partición estratificada de la cohorte alineada (9,351 galaxias).

Partición	Total	Tardías (1)	Tempranas (0)	% tardías
Entrenamiento	6,545	4,078	2,467	62.3
Validación	1,403	874	529	62.3
Prueba	1,403	875	528	62.4

El desbalance moderado (aprox. 62 % tardías) implica que un clasificador trivial que siempre predice "tardía" obtendría una exactitud de $875/1403 = 62.4\,\%$ con AUC $= 0.5$; este es el piso de referencia para interpretar cualquier exactitud.

La infraestructura se organizó como un repositorio modular (Figura **??**) que permite intercambiar encoders sin reescribir el entrenamiento y deja trazas reproducibles de cada corrida.

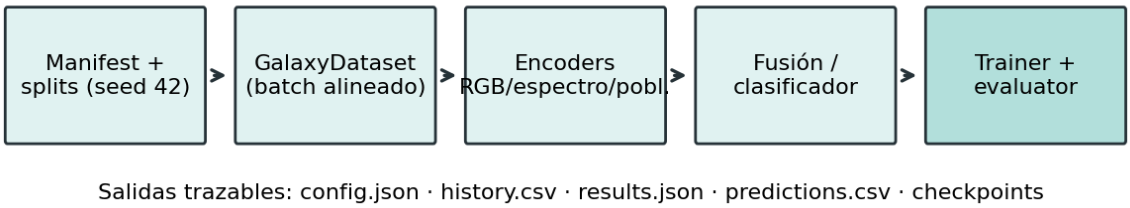


Figura 1: Pipeline experimental modular. Cada corrida produce configuración, historial, resultados, predicciones por galaxia y checkpoints, lo que habilita el análisis de errores pareado de la Sección **??**.

3. Metodología y modelos

3.1. Protocolo común

Todos los modelos se entrenaron con AdamW (**?**), pérdida `BCEWithLogitsLoss` y selección del checkpoint por AUC de validación; la evaluación se hizo en el mismo conjunto de prueba de 1,403 galaxias. La métrica primaria es ROC-AUC; la exactitud se reporta al umbral 0.5.

3.2. Línea base y ablación (Avance 3)

Se entrenaron encoders unimodales y combinaciones por concatenación:

- **RGB**: una CNN compacta de 4 bloques y ResNet-18 (**?**).
- **Espectro observado**: CNN1D con *pooling* global sobre `FLUX_FoV`.
- **Espectro STARLIGHT**: CNN1D sobre el espectro sintético.
- **Poblaciones**: MLP sobre las 2×45 fracciones.
- **Combinaciones**: RGB + espectros, RGB + poblaciones y trimodal.

Se adoptó como **línea base visual** la ResNet-18 (AUC $= 0.9633$; exactitud $= 88.8\,\%$), por ser la arquitectura estándar de referencia en la literatura de morfología. La Tabla **??** muestra el resultado.

Tabla 3: Ablación en el conjunto de prueba ($n = 1{,}403$). Exactitud al umbral 0.5.

Modalidad	**Modelo**	**ROC-AUC**	**Exactitud**
Imagen	CNN 4 bloques	0.9623	90.1 %
Imagen	ResNet-18 (**línea base**)	0.9633	88.8 %
Trimodal	RGB + espectro + poblaciones (concat.)	0.9650	89.0 %
Poblaciones	MLP STARLIGHT	0.8949	83.7 %
Espectro SL	CNN1D	0.8642	78.9 %
Espectro FoV	CNN1D	0.8572	79.5 %

La mejor fusión supera a la ResNet-18 por solo $\Delta\text{AUC} = +0.0017$, inferior a la incertidumbre del AUC (≈ 0.005): la mejora *no está demostrada*. El diagnóstico de curvas de aprendizaje reveló patrones distintos por modalidad (Tabla **??**): la imagen sobreajusta y el espectro subajusta. Por lo tanto, entrenar más no era la solución; había que cambiar la representación espectral.

Tabla 4: Diagnóstico de generalización (pérdida final de entrenamiento / validación).

Modelo	**Train / Val**	**Lectura**
CNN visual compacta	0.237 / 0.287	Sobreajuste leve tras la época 38; extender a 46 épocas no mejoró la prueba
ResNet-18 visual	0.159 / 0.317	Sobreajuste claro; también presente en las fusiones
CNN1D espectral	0.461 / 0.475	Subajuste / meseta: problema de representación y optimización

3.3. Modelos candidatos: rediseño del experto espectral (Avance 4)

La hipótesis fue que el *pooling* global de la CNN1D destruía las relaciones entre el continuo, el quiebre de 4000 Å y las líneas. Se probaron tres variantes, todas con tasa de aprendizaje 3×10^{-4}, recorte de gradiente 1.0 y mayor capacidad: (i) CNN profunda con *attention pooling* sin recurrencia (control), (ii) CNN + BiGRU (**?**) sobre 256 tokens y (iii) *Patch* + BiGRU (128 parches de 32 puntos, BiGRU de 2 capas).

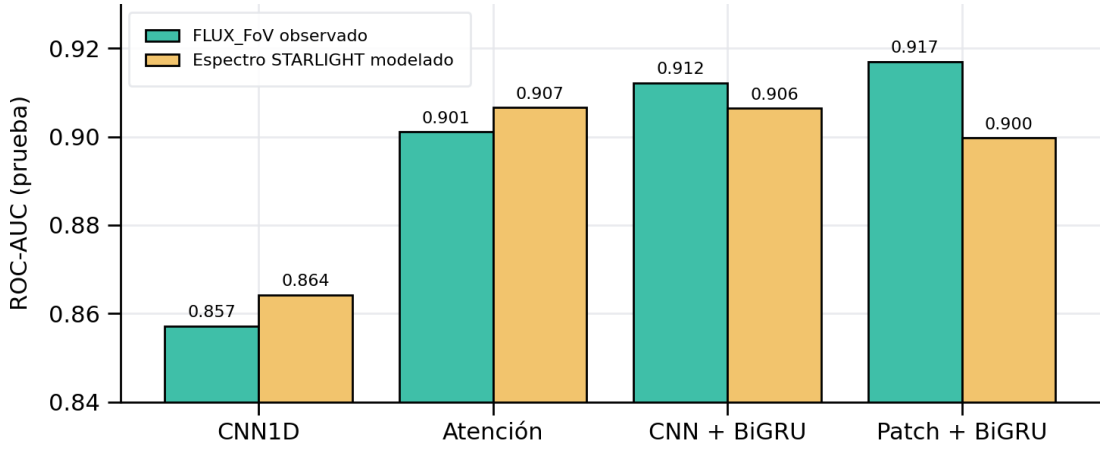


Figura 2: ROC-AUC en prueba de los encoders espectrales. El rediseño eleva el espectro observado de 0.857 a 0.917 (exactitud de 79.5 % a 85.2 %).

El espectro sí contenía más señal (Figura **??**): el mejor encoder FoV (Patch + BiGRU) alcanzó AUC = 0.9170 y exactitud = 85.2 %. El control con atención, sin recurrencia, ya llega a 0.9011 (FoV) y 0.9066 (STARLIGHT), por lo que la ganancia *no* puede atribuirse solo a la BiGRU: optimización y encoder cambiaron a la vez.

3.4. Selección del modelo final (Avance 5)

Un experto espectral más fuerte no garantizó una mejor fusión. Al concatenar la imagen con el encoder de atención sobre STARLIGHT, el AUC cayó de 0.9667 (imagen sola, mismo control de LR 3×10^{-4}) a 0.9334 (-0.0333); la fusión alcanzó su mejor checkpoint en la época 4 de 12, un síntoma compatible con atajos o memorización de la rama nueva. Es una sola corrida con una semilla: evidencia sugestiva, no prueba general.

La fusión tardía tampoco mejoró. Promediar probabilidades RGB y de poblaciones con un peso global α fijo produjo $\Delta\text{AUC} = +0.0005$ con IC 95 % $[-0.0012, +0.0022]$, que incluye el cero.

La decisión que importó. Se eligió como **modelo final** la **CNN visual entrenada con LR** 3×10^{-4} (AUC = 0.9667; exactitud = 89.5 %), y se descartó la fusión por concatenación como modelo de producción. El porqué es triple: (1) ninguna fusión mostró una ganancia estadísticamente defendible; (2) la fusión añade costo de inferencia y una dependencia del espectro que LSST no podrá satisfacer a escala; y (3) el análisis de errores (Sección **??**) reveló que la información complementaria existe, pero que la concatenación no es el mecanismo adecuado para explotarla. Esta decisión convierte un resultado aparentemente negativo ("la fusión no ayuda") en una hipótesis más precisa para el trabajo futuro.

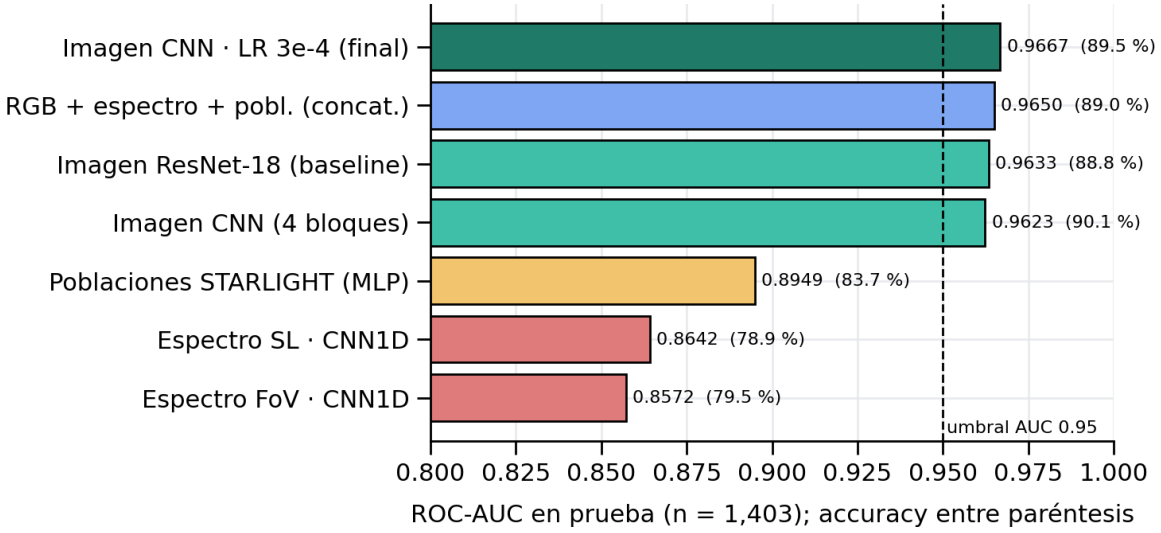


Figura 3: Trayectoria de modelos: espectrales, de poblaciones, visuales y fusión. La línea discontinua marca el umbral de aceptación ROC-AUC = 0.95.

4. Resultados y validación

4.1. Modelo final frente a línea base y umbrales

La Tabla **??** contrasta el modelo final con la línea base y con los criterios de la Tabla **??**.

El veredicto es mixto y debe leerse con honestidad: el sistema *cumple* la métrica primaria con margen, pero *no demuestra* la hipótesis multimodal y aún no tiene evidencia de calibración ni de exactitud balanceada. Además, la diferencia entre el modelo final y la línea base es menor que la incertidumbre del AUC; en la práctica, ambos son clasificadores visuales equivalentes, y la elección del final se justifica por su mayor AUC y su menor costo, no por una superioridad demostrada.

Tabla 5: Veredicto frente a los umbrales del proyecto. Brecha = observado − umbral.

Criterio	**Umbral**	**Observado**	**Brecha / estado**
ROC-AUC (métrica primaria)	≥ 0.95	0.9667	+0.0167 · **cumple**
Lift vs. línea base ResNet-18 (0.9633)	—	+0.0034 AUC; +0.7 pp exactitud	Menor que la incertidumbre (≈ 0.005): no significativo
Lift vs. clasificador trivial	—	+0.4667 AUC; +27.1 pp exactitud	Frente a AUC 0.5 y exactitud 62.4 %
Exactitud balanceada	≥ 0.90	No reportada	Pendiente; la exactitud global (89.5 %) queda −0.5 pp bajo 0.90
Calibración (ECE)	≤ 0.05	No medida	Pendiente
Mejora multimodal (IC 95 % excluye 0)	IC > 0	+0.0005 $[-0.0012, +0.0022]$	**No cumple**

4.2. Complementariedad: los errores no son idénticos

El análisis pareado por galaxia sobre las mismas 1,403 observaciones de prueba mostró que:

- la ResNet-18 visual comete **157 errores** (exactitud 88.8 %);
- el experto de poblaciones acierta el **51.6 %** de ellos; 76 errores son compartidos por ambos modelos;
- un oráculo que eligiera siempre el modelo correcto elevaría la exactitud de 0.888 a **0.946**.

El oráculo usa la etiqueta de forma retrospectiva: demuestra *potencial*, no un clasificador realizable. Su valor es acotar el beneficio máximo que un decisor adaptativo podría capturar.

4.3. Dónde se equivoca el modelo: la frontera morfológica

La dificultad se concentra en la frontera Ttype 0–1 (Figura **??**): estas galaxias son el 16.1 % de la muestra, pero concentran el **47.8 %** de los errores RGB, con una tasa de error de **33.2 %**. Fuera de esa frontera, el error visual es de solo **7.0 %**. Ninguna propiedad STARLIGHT individual separó significativamente los errores tras la corrección de Bonferroni, y la presencia de errores de alta confianza impide una regla simple basada solo en la incertidumbre.

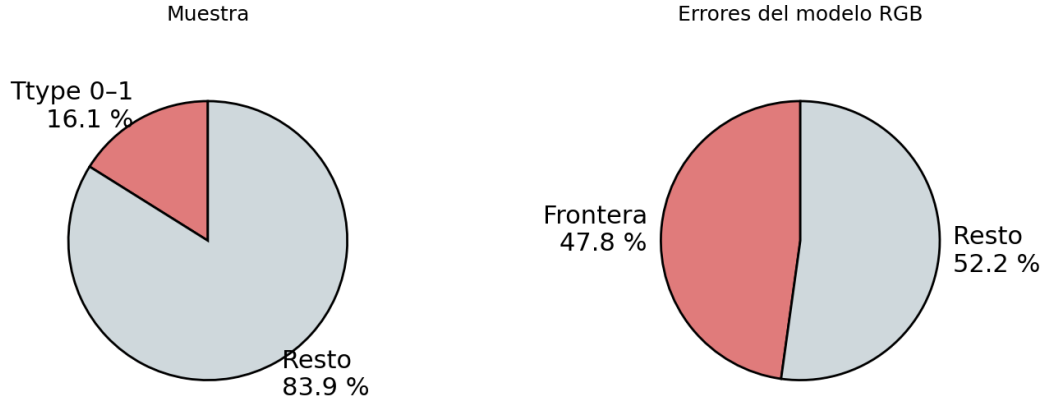


Figura 4: Concentración de errores. La frontera Ttype 0–1 es una minoría de la muestra, pero aporta casi la mitad de los errores del modelo visual.

4.4. Significado de los errores en el contexto del negocio

Un error no tiene el mismo costo científico en todas partes:

- **En la frontera (S0 frente a espirales tempranas)**, la propia etiqueta es ruidosa: la dispersión entre clasificadores humanos es máxima. Una discrepancia allí no necesariamente es un fallo del modelo; a menudo refleja una ambigüedad física real. Para el usuario, la acción correcta es *derivar a revisión* o reportar la probabilidad, no forzar una etiqueta.
- **Fuera de la frontera**, un error del 7.0 % sí es relevante: una espiral clasificada como temprana sesga fracciones morfológicas, relaciones masa-morfología y estudios de apagado de la formación estelar. Estos errores son los que justifican el monitoreo y la calibración.
- **En términos económicos**, la concentración de errores sugiere una política de cobertura: clasificar automáticamente las galaxias con probabilidad extrema y enviar a revisión experta una fracción pequeña, enriquecida en Ttype 0–1. La curva cobertura-precisión que fija ese corte aún debe medirse.

4.5. Limitaciones de validez integradas al resultado

- **Validez de etiquetas.** Ttype es un juicio humano; el techo alcanzable está limitado por el ruido en los tipos intermedios.
- **Contaminación entre modalidades.** STARLIGHT se deriva del mismo `FLUX_FoV`; espectro y poblaciones no son evidencia independiente.
- **Una semilla por experimento.** Las diferencias de milésimas de AUC no son robustas sin 3–5 semillas e intervalos pareados.
- **Confusión de factores.** En los encoders espectrales cambiaron a la vez la tasa de aprendizaje y la arquitectura.
- **Reutilización del conjunto de prueba.** Comparar muchas variantes contra el mismo test introduce un sesgo optimista de selección; la estimación final requiere un conjunto ciego no consultado.
- **Supuesto de transferencia.** Los resultados se obtienen en galaxias cercanas de MaNGA; la profundidad, el *seeing* y el corrimiento al rojo de LSST pueden degradar el desempeño.

5. Implementación y operación

Aunque el despliegue quedó fuera del alcance académico, CRISP-ML(Q) exige anticipar sus requisitos (**?**). Se propone una arquitectura centrada en el clasificador visual, con revisión experta en la zona incierta.

5.1. Requisitos para producción y responsables sugeridos

5.2. Arquitectura de despliegue

La Figura **??** muestra el flujo: las imágenes se ingieren y recortan con el mismo procedimiento del entrenamiento; el servicio de inferencia carga una versión registrada del modelo y produce $P(\text{tardía})$ calibrada; una política de decisión publica en el catálogo los casos de alta confianza y envía la zona incierta a revisión experta, cuyas etiquetas alimentan el reentrenamiento controlado.

Tabla 6: Requisitos de operación y responsables sugeridos.

Requisito	**Detalle**	**Responsable sugerido**
Ingesta y recorte	Descarga g, r, z; FOV = k·`PETRO_TH90`; 256×256; control de calidad e índices	Ingeniería de datos
Versionado de datos y modelo	Manifest, split, checksums, `config.json` y *model card* en un registro de modelos	Ingeniería de ML (MLOps)
Calibración	Ajuste de temperatura o isotónico en validación; ECE ≤ 0.05 antes de promover	Ciencia de datos
Política de decisión	Umbrales de probabilidad para auto-clasificar y para derivar a revisión; curva cobertura-precisión	Responsable del proyecto + experto de dominio
Revisión experta	Cola priorizada (Ttype 0–1 probable, baja confianza); etiquetas nuevas versionadas	Experto de dominio (astrónomo/a)
Infraestructura de inferencia	Contenedor reproducible, inferencia por lotes en GPU/CPU, registro de latencia y costo	Ingeniería de plataforma
Monitoreo y alertas	Tablero de deriva y desempeño; umbrales de alerta	MLOps + ciencia de datos
Reentrenamiento	Pipeline reproducible, mismo protocolo de split, test bloqueado, comparación contra el modelo vigente	Ingeniería de ML
Gobernanza	Aprobación de cada versión; trazabilidad modelo-catálogo	Responsable del proyecto

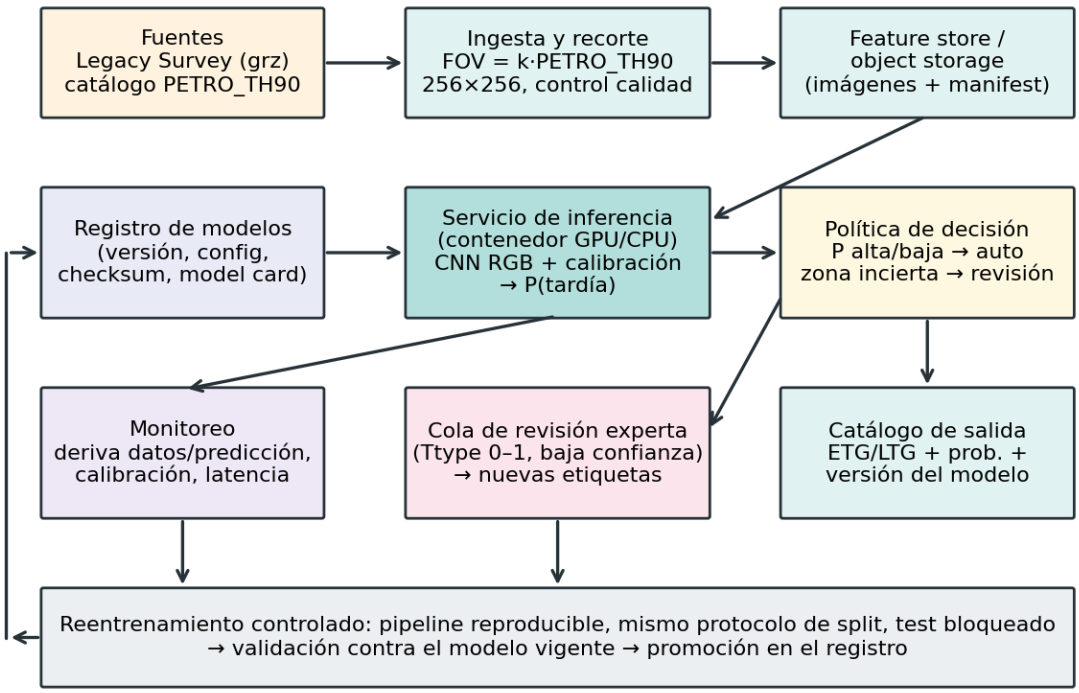


Figura 5: Arquitectura de despliegue propuesta para el clasificador visual con revisión humana en la zona incierta y ciclo de reentrenamiento controlado.

El diseño es modular: si en el futuro se valida un decisor adaptativo, el experto espectral se añadiría como servicio opcional, invocado solo para galaxias con espectro y en la zona incierta, sin alterar la ruta principal.

5.3. Monitoreo

Tabla 7: Aspectos a supervisar durante la operación.

Aspecto	**Indicador**	**Acción ante alerta**
Deriva de datos	Distribución de `PETRO_TH90`, brillo, color y profundidad; región norte/sur del Legacy Survey	Revisar recorte; evaluar por subgrupo
Deriva de predicción	Fracción predicha de tardías frente al 62 % esperado; histograma de probabilidades	Auditoría de muestra
Calibración	ECE y Brier sobre las etiquetas de revisión experta	Recalibrar
Desempeño por segmento	AUC y error en Ttype 0–1, galaxias de canto y pequeñas	Reentrenar o ajustar la política
Cobertura	% auto-clasificado con precisión $\geq 95\,\%$; volumen de la cola de revisión	Ajustar umbrales
Calidad de entrada	Recortes vacíos, estrellas superpuestas, artefactos	Filtrar en la ingesta
Operación	Latencia, galaxias/hora-GPU, costo, fallos	Escalar infraestructura
Explicabilidad	Muestreo periódico de mapas Grad-CAM (**?**)	Detectar atajos ("Clever Hans")

6. Conclusiones clave

6.1. Hallazgos principales

1. **La imagen es la referencia difícil de superar.** El modelo final visual alcanza ROC-AUC = 0.9667 y exactitud = 89.5 %, por encima del umbral de 0.95 (+0.0167). Su ventaja sobre la línea base ResNet-18 (+0.0034) no es significativa.

2. **La hipótesis multimodal, tal como se formuló, no se confirmó.** Ninguna fusión mostró una mejora con un IC 95 % que excluya el cero; la concatenación con un experto espectral más fuerte incluso degradó el AUC en 0.0333.

3. **El espectro no era débil por falta de información.** Rediseñar el encoder elevó el AUC espectral de 0.857 a 0.917.

4. **La complementariedad existe, pero no está explotada.** Las poblaciones corrigen el 51.6 % de los errores visuales; el oráculo acota el potencial en una exactitud de 0.946.

5. **El error se concentra en la frontera física.** El 47.8 % de los errores ocurre en Ttype 0–1, donde la etiqueta es más ambigua.

6.2. Limitaciones

Las conclusiones descansan en corridas de una sola semilla, en un conjunto de prueba reutilizado durante la selección, en etiquetas humanas ruidosas en la frontera y en dos "modalidades" espectrales que no son independientes. No se midieron la calibración, la exactitud balanceada ni la curva cobertura-precisión, de modo que el cumplimiento de los criterios económicos sigue abierto. Finalmente, el desempeño en galaxias cercanas de MaNGA no garantiza la transferencia a LSST.

6.3. Trabajo futuro

1. **Reproducibilidad**: 3–5 semillas, intervalos pareados por bootstrap y prueba de McNemar (**?**), reportando AUC y exactitud balanceada.
2. **Calibración y análisis de errores**: ECE/Brier, diagramas de confiabilidad (**?**) y subgrupos por Ttype y masa.
3. **Decisor adaptativo por galaxia**: $p_{\text{final}} = \alpha(x)\, p_{\text{RGB}} + [1 - \alpha(x)]\, p_{\text{experto}}$, aprendido solo con predicciones fuera de pliegue (*out-of-fold*) en entrenamiento y validación, con el test bloqueado; comparar fusión ponderada, *stacking* y un *gating* pequeño.
4. **Destilación para LSST**: transferir lo aprendido por un modelo multimodal "maestro" a un estudiante solo-imagen, útil cuando no haya espectro.
5. **Robustez**: ruido y PSF degradada, variación del factor de encuadre $\pm 20\,\%$, invariancia a rotaciones y enmascaramiento de ventanas espectrales (Hα, quiebre de 4000 Å).
6. **Etiquetas**: tratar la frontera Ttype 0–1 como clase de incertidumbre o usar etiquetas blandas a partir de la dispersión entre clasificadores (**?**).

7. Referencias y anexos

Bundy, K., Bershady, M. A., Law, D. R., et al. (2015). Overview of the SDSS-IV MaNGA survey: Mapping nearby galaxies at Apache Point Observatory. *The Astrophysical Journal*, *798*(1), 7. https://doi.org/10.1088/0004-637X/798/1/7

Buta, R. J. (2013). Galaxy morphology. En T. D. Oswalt & W. C. Keel (Eds.), *Planets, stars and stellar systems* (Vol. 6, pp. 1–89). Springer. https://doi.org/10.1007/978-94-007-5609-0_1

Cho, K., van Merriënboer, B., Gulcehre, C., et al. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. En *Proceedings of EMNLP 2014* (pp. 1724–1734). https://doi.org/10.3115/v1/D14-1179

Cid Fernandes, R., Mateus, A., Sodré, L., Stasińska, G., & Gomes, J. M. (2005). Semi-empirical analysis of Sloan Digital Sky Survey galaxies – I. Spectral synthesis method. *Monthly Notices of the Royal Astronomical Society*, *358*(2), 363–378. https://doi.org/10.1111/j.1365-2966.2005.08752.x

Dey, A., Schlegel, D. J., Lang, D., et al. (2019). Overview of the DESI Legacy Imaging Surveys. *The Astronomical Journal*, *157*(5), 168. https://doi.org/10.3847/1538-3881/ab089d

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, *10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330). PMLR.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90

Hubble, E. P. (1926). Extragalactic nebulae. *The Astrophysical Journal*, *64*, 321–369. https://doi.org/10.1086/143018

Ivezić, Ž., Kahn, S. M., Tyson, J. A., et al. (2019). LSST: From science drivers to reference design and anticipated data products. *The Astrophysical Journal*, *873*(2), 111. https://doi.org/10.3847/1538-4357/ab042c

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*.

Nair, P. B., & Abraham, R. G. (2010). A catalog of detailed visual morphological classifications for 14,034 galaxies in the Sloan Digital Sky Survey. *The Astrophysical Journal Supplement Series*, *186*(2), 427–456. https://doi.org/10.1088/0067-0049/186/2/427

Selvaraju, R. R., Cogswell, M., Das, A., et al. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision* (pp. 618–626). https://doi.org/10.1109/ICCV.2017.74

Studer, S., Bui, T. B., Drescher, C., et al. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction*, *3*(2), 392–413. https://doi.org/10.3390/make3020020

Vázquez-Mata, J. A., Hernández-Toledo, H. M., Avila-Reese, V., et al. (2022). SDSS IV MaNGA: Visual morphological and statistical characterization of the DR15 sample. *Monthly Notices of the Royal Astronomical Society*, *512*(2), 2222–2244. https://doi.org/10.1093/mnras/stac635

Walmsley, M., Lintott, C., Géron, T., et al. (2022). Galaxy Zoo DECaLS: Detailed visual morphology measurements from volunteers and deep learning for 314 000 galaxies. *Monthly Notices of the Royal Astronomical Society*, *509*(3), 3966–3988. https://doi.org/10.1093/mnras/stab2093

Anexo A. Glosario

Término	**Definición**
ETG / LTG	Galaxia temprana (elíptica o lenticular) / tardía (espiral o irregular)
Ttype	Codificación numérica de la secuencia de Hubble; ≤ 0 temprana, 1–10 tardía
`PETRO_TH90`	Radio que encierra el 90 % de la luz petrosiana; controla el encuadre
`FLUX_FoV`	Espectro integrado en todo el campo del IFU de MaNGA
STARLIGHT	Código de síntesis espectral que ajusta el espectro con 45 plantillas de poblaciones
ROC-AUC	Probabilidad de que el modelo ordene una tardía por encima de una temprana elegidas al azar
ECE	Error esperado de calibración: discrepancia entre la probabilidad predicha y la frecuencia observada
Oráculo	Selector ideal que elige el modelo correcto con conocimiento de la etiqueta (cota superior)

Anexo B. Trazabilidad de cifras y artefactos

Todas las cifras del artículo provienen del informe integrado de avances (noviembre de 2026) y de los notebooks del repositorio del proyecto (https://github.com/Melonangie/Galaxy-Vision, carpetas `Notebooks/avances` y `Notebooks/julio`). Cada corrida conserva `config.json`, `history.csv`, `results.json`, `predictions.csv`, matrices de confusión y checkpoints. Los criterios de la Tabla **??** provienen del documento de planeación CRISP-ML(Q) del proyecto.

Tabla 8: Resumen de cifras decisivas.

Cifra	**Valor**
Cohorte alineada / manifest	9,351 / 10,014
Clasificador trivial (exactitud; AUC)	62.4 %; 0.500
Línea base ResNet-18 (AUC; exactitud; errores)	0.9633; 88.8 %; 157
Modelo final CNN visual LR 3×10^{-4} (AUC; exactitud)	0.9667; 89.5 %
Lift final vs. línea base (AUC)	+0.0034
Brecha frente al umbral AUC 0.95	+0.0167
Mejor encoder espectral (Patch + BiGRU, FoV)	0.9170; 85.2 %
Fusión tardía ΔAUC (IC 95 %)	$+0.0005$ $[-0.0012, +0.0022]$
Concatenación con atención SL ΔAUC	-0.0333
Errores RGB corregidos por poblaciones / oráculo	51.6 % / 0.946
Frontera Ttype 0–1: muestra / errores / tasa	16.1 % / 47.8 % / 33.2 %