INFORME DE AVANCES · NOVIEMBRE 2026

Clasificación morfológica multimodal de galaxias

Datos → infraestructura → ablación → espectros → complementariedad → fusión adaptativa

0.963

AUC del baseline visual

Accuracy test: 88.8 %

0.917

Mejor AUC espectral

Accuracy test: 85.3 %

0.946

Accuracy del oráculo RGB ∪ poblaciones

Revisión técnica de resultados y siguientes hipótesis

NARRATIVA

De una pregunta multimodal a una hipótesis de decisión

Qué cambió durante la investigación

01	**Disponibilidad**	Tres fuentes principales y catálogo curado
02	**Comparabilidad**	Cohorte, split y entrenamiento compartidos
03	**Ablación**	La imagen domina; concatenar no basta
04	**Espectros**	Atención / BiGRU recuperan señal útil
05	**Complementariedad**	Los errores no son idénticos
06	**Siguiente hipótesis**	Aprender cuándo confiar en cada experto

Qué datos tenemos disponibles

Una única galaxia puede describirse mediante estructura, luz integrada y contexto físico

Imagen RGB

Legacy Survey · JPEG

7 encuadres FoV · 256 × 256 · grz

- Field of view adaptativo: FOV = k × PETRO_TH90
- Capas ls-dr11; índices y revisión de calidad
- 10,006 imágenes disponibles por factor

Espectro MaNGA

MPL-11 · FITS

FLUX_FoV / FLUX_1RE

- WAVE, flujos y errores por apertura
- 10,013 FITS presentes de 10,014 objetos
- Cachés 4096 puntos, marco de reposo

STARLIGHT

Derivados del espectro FoV

45 plantillas · 90 features de población

- Espectro sintético del mejor ajuste
- Fracciones de luz y masa actual por plantilla
- Propiedades físicas derivadas

Importante: STARLIGHT no es una observación independiente; sus productos se derivan del mismo FLUX_FoV.

Un protocolo común hace comparables los experimentos

Identidad por name, particiones persistentes y restricciones contra fuga de datos

10,014
Filas del manifest maestro

9,351
Galaxias de la cohorte alineada

42
Semilla del split estratificado

Partición	Total	Tardías	Tempranas
Entrenamiento	6,545	4,078	2,467
Validación	1,403	874	529
Prueba	1,403	875	528

Mismo split para todas las ramas · test reservado · sin Ttype/Type/label como features

Repositorio modular: de insumos a evidencia reproducible

Diseñado para intercambiar modelos sin reescribir el entrenamiento

Manifest + splits
ID, disponibilidad, calidad

→

GalaxyDataset
Batch multimodal alineado

→

Encoders
RGB / espectro / poblaciones

→

Fusión / clasificador
Logits binarios

→

Trainer + evaluator
Checkpoint + métricas

Entradas controladas

- Cachés espectrales + máscaras; transformaciones RGB
- Configuración de modalidades y FoV; validación de IDs

Salidas trazables

- config.json / history.csv / results.json
- predictions.csv, matrices y checkpoints

Documentación: EXPERIMENT_GUIDELINES.md. La guía combina módulos implementados con líneas de desarrollo futuro.

Qué alternativas se compararon

Ablación de encoders unimodales y concatenaciones bajo la misma cohorte

RGB	CNN 4 bloques; ResNet-18	Referencia morfológica
Espectro observado	CNN1D sobre FLUX_FoV	Información espectroscópica
Espectro STARLIGHT	CNN1D sobre síntesis modelada	Representación espectral alternativa
Poblaciones	MLP sobre 2 × 45 fracciones	Contexto de edad / metalicidad
Combinaciones	RGB + espectros; RGB + poblaciones; trimodal	¿Aporta una segunda rama?

Entrenamiento: AdamW, BCEWithLogitsLoss, selección por AUC de validación; checkpoint óptimo y test alineado.

Las imágenes dominan el rendimiento predictivo

AUC en test · accuracy a umbral 0.5 (anotación a la derecha)



ΔAUC ResNet vs mejor fusión = +0.0017; incertidumbre del AUC ≈ 0.005 → mejora no demostrada.

El problema no era simplemente entrenar más

Patrones de generalización diferentes por modalidad

CNN visual compacta

0.237 / 0.287

train / val loss (final)

Sobreajuste leve tras época 38

Extender hasta 46 épocas no mejoró test

ResNet-18 visual

0.159 / 0.317

train / val loss (final)

Sobreajuste claro

También aparece en fusiones; no es culpa exclusiva de combinar insumos

CNN1D espectral

0.461 / 0.475

train / val loss (final)

Subajuste / plateau

Problema de representación y optimización, no de más regularización

Conclusión: augmentations/scheduler en imagen; revisar normalización, LR y arquitectura en espectros.

Replanteamos el experto espectral

Hipótesis: pooling global CNN1D perdía relaciones entre continuo, quiebre 4000 Å y líneas

Referencia

CNN1D + pooling global

LR 1e–4

Control atención

CNN profunda + attention pooling

Sin recurrencia

CNN + BiGRU

Extracción local + integración secuencial

256 tokens

Patch + BiGRU

128 patches × 32 + BiGRU

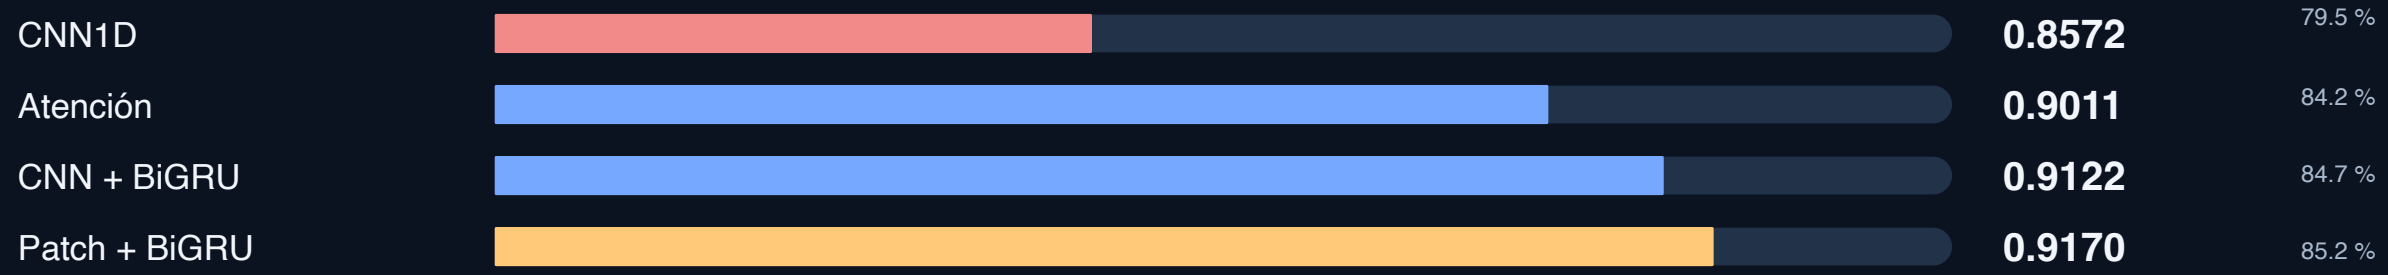
2 capas

Nuevas variantes: LR 3e–4 + gradient clipping 1.0 + más capacidad. No atribuir la ganancia solo a BiGRU.

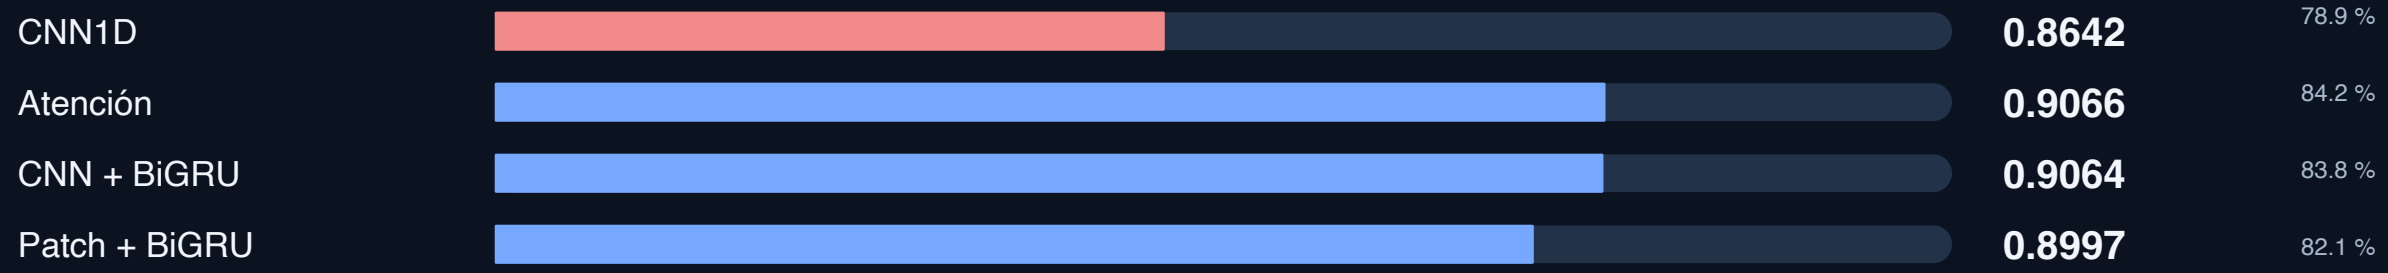
El espectro sí contenía más señal de la que extraía la CNN1D

AUC en test · accuracy (%) anotada a la derecha para cada modelo

FoV observado



STARLIGHT modelado



Mejor FoV 0.917; atención sin recurrencia alcanza 0.901 FoV / 0.907 SL. Cambiaron simultáneamente optimización y encoder.

Un experto espectral más fuerte no garantiza una fusión mejor

Experimento adicional: CNN con atención sobre espectro STARLIGHT

0.9667

AUC imagen sola · control LR 3e–4

Accuracy test: 89.5 %

0.9334

AUC RGB + espectro SL atención · concat

Accuracy test: 86.2 %

–0.0333 AUC

La fusión concatenada se detuvo con su mejor checkpoint en la época 4 (de 12). La nueva rama puede introducir atajos / memorizar, aunque aisladamente sea más informativa.

Una corrida, una semilla: evidencia sugestiva, no prueba general de que toda fusión espectral perjudica.

Los errores no son idénticos: existe información rescatable

Análisis por galaxia sobre las mismas 1,403 observaciones de test

157

Errores del ResNet visual

51.6 %

Errores RGB corregidos por poblaciones

76

Errores compartidos RGB ∩ poblaciones

0.888 → 0.946

Accuracy del oráculo RGB ∪ poblaciones

+0.0005

ΔAUC de fusión tardía (IC95 %: −0.0012 a +0.0022)

El oráculo usa conocimiento retrospectivo de la etiqueta: demuestra potencial, NO un clasificador realizable.

La dificultad se concentra en la frontera morfológica

Ttype 0–1 presenta ambigüedad física y visual

16.1 %

De las galaxias están en Ttype 0–1

47.8 %

De errores RGB ocurren allí

33.2 %

Tasa de error RGB en frontera

Fuera de esa frontera: error RGB de solo 7.0 %

No se identificó una propiedad STARLIGHT individual que separe significativamente los errores tras corrección Bonferroni.

La superposición entre clases y los errores de alta confianza limitan cualquier regla sencilla basada solo en incertidumbre.

De concatenación a un decisor adaptativo de probabilidades

Hipótesis: aprender cuándo confiar en la imagen y cuándo en el experto físico

Experto RGB

pRGB + confianza / calibración

Experto alternativo

pEsp o pPoblaciones

→

Gating / stacking calibrado

Peso por objeto α(x), no un α global fijo

↓

$$p\ final = \alpha(x) \cdot pRGB + [1-\alpha(x)] \cdot pExperto$$

El gate debe aprenderse exclusivamente en train/validación (idealmente predicciones out-of-fold); test permanece bloqueado.

Experimentos que decidirán si la fusión adaptativa vale la pena

Priorizar evidencia comparativa antes de aumentar la complejidad

1	**Reproducibilidad**	3–5 semillas; intervalos pareados; AUC y balanced accuracy
2	**Expertos finales**	RGB CNN/ResNet; FoV patch-BiGRU; MLP STARLIGHT
3	**Calibración y errores**	ECE/Brier; confiabilidad; subgrupos de Ttype y masa
4	**Decisor mínimo**	Late fusion ponderada, stacking OOF, gating pequeño
5	**Controles**	Comparar con RGB sola; evitar leakage y sobreajuste
6	**Decisión científica**	Ganancia estadísticamente defendible y costo de inferencia

Conclusiones principales

Lo aprendido ya permite formular la siguiente pregunta experimental con precisión

01 **El RGB es la referencia difícil de superar**

AUC ≈ 0.963 y accuracy ≈ 89–90 %; las fusiones no mejoran de forma concluyente.

02 **El espectro no era débil por falta de información**

AUC hasta 0.917 y accuracy 85.2 %, frente a 0.857 y 79.5 % con CNN1D FoV.

03 **La complementariedad existe, pero no está explotada**

Poblaciones corrigen 51.6 % de errores visuales; α fijo no mejora test.

04 **La siguiente hipótesis es una decisión por galaxia**

Ensamble calibrado y controlado, frente a una referencia visual sólida.